

QWEN MEETUP TOKYO · INTERMEDIATE REPORT

When Does a Local LLM Start to Break?

「入る文脈」と「使える能力」は、同じではない。

Qwen3.8-27B / llama.cpp / calibrated scorer

Context → quantization → interaction → agent history

“Break”を3つに分けて測る

Capability

答えを含むか。
正確に答えられるか。
形式も満たすか。

Systems cost

モデルは小さくなるか。
長い入力を現実的な時間で
処理できるか。

Trajectory reliability

発見した事実を、
長い履歴のあとでも
最終状態まで使えるか。

スペック上のcontext windowではなく、能力が崩れる地点を測る。

Scope: calibrated real-model measurements; fixture and incomplete matrices are kept separate.

4つの実験を、1本の測定ストーリーにする



観測された失敗を、モデル・評価器・出力プロトコルに分解していく。

Source: docs/findings.md; raw manifests and processed summaries for exp_001–exp_004.

exp_001 — 長い文脈を「使える」とは限らない

75s → 339.5s

median stream-derived TTFT

8K → 32K

answer-bearing correctnessは全セル10/10。
しかしend-to-end successは形式条件に左右された。

TASK FAMILY	8K	32K
literal	2/10	6/10
semantic	4/10	3/10
multi-hop	8/10	9/10

baseline matrixはp50のみ。別のfeasibility probeは固定3タスク・p50で、position biasはまだ測っていない。


exp_001 feasibility — 262Kは「入る」前に時間で壊れる

TARGET CONTEXT	ATTEMPTS	CLASSIFICATION	OBSERVED BOUNDARY
64K	3/3 completed	accepted + useful	answer-bearing 3/3 · TTFT 783–786s
128K	3/3 attempted	operational failure	3/3 timeout at 900s · RSS ≈ 37.6GB
262K	3/3 attempted	operational failure	3/3 timeout at 900s · RSS ≈ 46.2GB

64Kでは、exact/formatではなく answer-bearing correctnessで3タスクとも通過。

Q8 · p50 · 固定3タスク · 各1回 · 900秒timeoutの結果。262Kの一般的なeffective contextを意味しない。

exp_002 — 量子化で小さくなるが、品質の問いは単純ではない



VARIANT	END-TO-END	ANSWER-BEARING
Q8	32/60	60/60
Q6	32/60	60/60
Q5	32/60	60/60
Q4	27/60	59/60

paired equivalence (95% CI, ±10pp) : answer-bearingは同等範囲内。exact/end-to-endとformat-validは同等性未確定。
timing probesは474/1,200。

exp_003 — 量子化×文脈のinteractionは「タスク依存」

TASK FAMILY	Q8 8K → 32K	Q4 8K → 32K	INTERACTION
literal	2/10 → 6/10	2/10 → 4/10	context-dependent
semantic	4/10 → 3/10	3/10 → 3/10	≈ constant
multi-hop	8/10 → 9/10	7/10 → 8/10	≈ constant

120/120
completed matched trials

p50
evidence position only

64K/128K
not measured

「Q4は常に悪い」でも「Q4とQ8は常に同じ」でもない。

Calibrated matched pilot · one greedy run per independent task · descriptive labels, not significance tests.

exp_004 — agentの失敗は、履歴長だけでは説明できない

300/300

final task success

trajectory 1 → 32

300/300

critical-fact reuse

0

planning errors

Protocol changed the observation

- 以前のpilot : 64-token limitで30件がinvalid output
- recheck : 128-token JSON + 3 action attempts
- 最大completionは109 tokens、全件成功

これは因果ablationではない。出力予算とretry policyが同時に変わっている。

固定ポリシー下では、履歴長による劣化は観測されなかった。

Q8_0/Q4_K_M · trajectory 1/4/8/16/32 · p50 · 10 tasks × 3 deterministic repeats

5つの強い主張を、証拠の強さに合わせて言い換える

境界を観測 262Kまで有効に使える？

このQ8環境では64Kは通過、128K/262Kは900秒timeout。一般的な effective contextではない。

指標限定 Q4とQ8は同等？

answer-bearingは-1.7pp (95% CI -5.0~0.0pp) で±10pp内。
exact/formatは同等性未確定。

未確認 position bias？

p50のみ測定。全position sweepが必要。

支持せず 履歴が長いほど悪化？

固定ポリシーのrecheckでは300/300。普遍則ではない。

未測定 repositoryでも再現？

exp_005のcurated vs broad pilotが次の検証。

Claim boundary follows the experiment manifests, scorer version, task catalog, and raw-result provenance.

TAKEAWAY

Fits $\neq$ Useful

モデルを評価する前に、
評価器と出力プロトコルを校正する。

1 · Scorer

exact / answer-bearing / formatを分離

2 · Position

matched evidence sweep

3 · Transfer

repository task validation

Current status: exp_001 baseline + bounded feasibility probe; exp_002–exp_004 measured or pilot; exp_005 remains unmeasured.