

QWEN MEETUP TOKYO · INTERMEDIATE REPORT

When Does a Local LLM Start to Break?

「入る文脈」と「使える能力」は、同じではない。

Qwen3.8-27B / llama.cpp / calibrated scorer

Context → quantization → interaction → agent history

“Break”を3つに分けて測る

Capability

答えを含むか。
正確に答えられるか。
形式も満たすか。

Systems cost

モデルは小さくなるか。
長い入力を現実的な時間で
処理できるか。

Trajectory reliability

発見した事実を、
長い履歴のあとでも
最終状態まで使えるか。

スペック上のcontext windowではなく、能力が崩れる地点を測る。

Scope: calibrated real-model measurements; fixture and incomplete matrices are kept separate.

4つの実験を、1本の測定ストーリーにする



Source: docs/findings.md; raw manifests and processed summaries for exp_001–exp_004.

exp_001 — 長い文脈を「使える」とは限らない

75s → 339.5s

median stream-derived TTFT


8K → 32K

answer-bearing correctnessは全セル10/10。
しかしend-to-end successは形式条件に左右された。

TASK FAMILY	8K	32K
literal	2/10	6/10
semantic	4/10	3/10
multi-hop	8/10	9/10

p50のみ。64K/128Kとposition biasはまだ測っていない。

exp_002 — 量子化で小さくなるが、品質の問いは単純ではない



VARIANT	END-TO-END	ANSWER-BEARING
Q8	32/60	60/60
Q6	32/60	60/60
Q5	32/60	60/60
Q4	27/60	59/60

このsynthetic catalog・1 greedy runでは、Q4/Q8の一般的な品質同等性は確定しない。timing probesも474/1,200と未完。

exp_003 — 量子化×文脈のinteractionは「タスク依存」

TASK FAMILY	Q8 8K → 32K	Q4 8K → 32K	INTERACTION
literal	2/10 → 6/10	2/10 → 4/10	context-dependent
semantic	4/10 → 3/10	3/10 → 3/10	≈ constant
multi-hop	8/10 → 9/10	7/10 → 8/10	≈ constant

120/120
completed matched trials

p50
evidence position only

64K/128K
not measured

「Q4は常に悪い」でも「Q4とQ8は常に同じ」でもない。

Calibrated matched pilot · one greedy run per independent task · descriptive labels, not significance tests.

exp_004 — agentの失敗は、履歴長だけでは説明できない

300/300

final task success

trajectory 1 → 32

300/300

critical-fact reuse

0

planning errors

Protocol changed the observation

- 以前のpilot : 64-token limitで30件がinvalid output
- recheck : 128-token JSON + 3 action attempts
- 最大completionは109 tokens、全件成功

これは因果ablationではない。出力予算とretry policyが同時に変わっている。

固定ポリシー下では、履歴長による劣化は観測されなかった。

Q8_0/Q4_K_M · trajectory 1/4/8/16/32 · p50 · 10 tasks × 3 deterministic repeats

5つの強い主張を、証拠の強さに合わせて言い換える

未測定 262Kまで有効に使える？

まず実行可能性probe。受け入れられることと有用性を分ける。

限定的 Q4とQ8は同等？

answer-bearingでは近いが、exact/formatまで同等とは言わない。

未確認 position bias？

p50のみ測定。全position sweepが必要。

支持せず 履歴が長いほど悪化？

固定ポリシーのrecheckでは300/300。普遍則ではない。

未測定 repositoryでも再現？

exp_005のcurated vs broad pilotが次の検証。

Claim boundary follows the experiment manifests, scorer version, task catalog, and raw-result provenance.

TAKEAWAY

Fits $\neq$ Useful

モデルを評価する前に、
評価器と出力プロトコルを校正する。

1 · Feasibility

64K / 128K / 262Kの実行可能性

2 · Position

matched evidence sweep

3 · Transfer

repository task validation

Current status: exp_001–exp_004 measured or pilot; exp_005 remains unmeasured.