

QWEN MEETUP TOKYO · LOCAL LLM EXPERIMENTS

When Does a Local Qwen Start to Break?

量子化して、長い文脈を入れて、それでも使えるのか？

Qwen3.8-27B / llama.cpp / Apple Silicon 64GB

Quantization × Context × Evaluation × Agent History

WHOAMI



Shoto Morisaki ✓ He/Him

Engineer who likes coffee

Santa Cruz, California, United States · [Contact info](#)

[453 followers](#) · [366 connections](#)

 University of California, Santa Cruz

Qwen Model とは？

 **Qwen/Qwen3.8-27B**   like 13.8k  Follow  Qwen 102k

 Image-Text-to-Text  Transformers  Safetensors qwen3_5 conversational  Eval Results  License: apache-2.0

 **Model card**  Files and versions  xet  Community **183**

Sources: Qwen official blog / Qwen3.8-27B official Hugging Face model repository (checked 2026-09-03)

なぜローカルで動かす？ そして、なぜ量子化する？

Local LLM の魅力

- データを外に出さずに試せる
- APIコストやrate limitを気にせず反復できる
- モデル内部の条件を固定して、実験しやすい

でも、27Bをそのまま載せるには重い。

Quantization

Q8

29.05 GB

Q6

22.43 GB

Q4

16.81 GB

重みを少ないbitで表現して軽くする。
では、軽くした代わりに何を失うのか？

Measured artifact size in exp_002 · Q8_0 / Q6_K / Q4_K_M

量子化とは



モデルが軽くなる 容量・メモリを節約

トレードオフ 少し誤差が入る

概念図：重みの表現を粗くして、モデルを軽量化する

LLM.int8()




Figure 2: Schematic of LLM.int8(). Given 16-bit floating-point inputs $\mathbf{X}_{f16}$ and weights $\mathbf{W}_{f16}$, the features and weights are decomposed into sub-matrices of large magnitude features and other values. The outlier feature matrices are multiplied in 16-bit. All other values are multiplied in 8-bit. We perform 8-bit vector-wise multiplication by scaling by row and column-wise absolute maximum of C_x and C_w and then quantizing the outputs to Int8. The Int32 matrix multiplication outputs Out_{i32} are dequantization by the outer product of the normalization constants $C_x \otimes C_w$. Finally, both outlier and regular outputs are accumulated in 16-bit floating point outputs.

今回、知りたかったこと

RQ1・Context

長い文脈を入れたとき、
情報を最後まで正しく使えるか？

RQ2・Quantization

Q8 → Q4で、
回答能力はどこまで残るか？

RQ3・Interaction

長い文脈 × 強い量子化で、
劣化は増幅するか？

さらに、agent historyまで伸ばしたとき一度見つけた事実を最後まで使えるかも確認した。

"Break" をどう測ったか

Task

Context

distractor / noise

KEY = ZX-4817

distractor / noise

Q: What is the key?

literal

そのまま拾う

semantic

意味を理解して拾
う

multi-hop

複数情報をつなぐ

exact matchだけでなく、**answer-bearing / format-valid / end-to-end**を分離して採点。

Context Window は使える長さではない

75s → 339.5s

median stream-derived TTFT

8K → 32K

8K / 32Kでは、answer-bearing correctnessは全セル
10/10。

しかし正答したことと指定形式まで満たしたことは別だった。

TARGET	RESULT	OBSERVED BOUNDARY
64K	3/3 complete	TTFT 783–786s
128K	3/3 timeout	900s · RSS ≈ 37.6GB
262K	3/3 timeout	900s · RSS ≈ 46.2GB


入るより先に、待てないが実用上の限界になった。

Q8_0 · baseline 60/60 + feasibility probe 9 attempts · 900s timeout

Feasibility Boundary

Baseline quality is task-shaped—not one context curve

Q8_0 · 10 independent tasks per family and context · p50 evidence position



Q4で-42.1%。では、賢さも42%落ちる？

Artifact footprint

Q8		29.05 GB
Q6		22.43 GB
Q5		19.54 GB
Q4		16.81 GB



VARIANT	END-TO-END	ANSWER-BEARING
Q8	32/60	60/60
Q6	32/60	60/60
Q5	32/60	60/60
Q4	27/60	59/60

answer-bearingではQ4もほぼ維持。
量子化 = 一律に大きく劣化ではなかった。

exact / format / end-to-endの同等性は未確定。

Footprint vs. Quality, per Metric

Quantization trades 42% less storage for metric-specific quality changes




Qwen3.8-27B · llama.cpp · 240 capability trials · 30 independent tasks · p50 evidence position

Q4/Q8同等性はメトリック次第

Q4/Q8 equivalence is metric-specific

Matched pairs · 60 pairs · 95% paired bootstrap CI · practical margin ± 10 percentage points



Answer-bearingは同等。End-to-end / Format-validはまだinconclusive。

Context × Quantization はタスク依存

TASK FAMILY	Q8 8K → 32K	Q4 8K → 32K	OBSERVATION
literal	2/10 → 6/10	2/10 → 4/10	context-dependent
semantic	4/10 → 3/10	3/10 → 3/10	≈ constant
multi-hop	8/10 → 9/10	7/10 → 8/10	≈ constant

120/120

matched trials

p50

evidence position only

Not yet


full position sweep

Calibrated matched pilot · descriptive interaction, not significance test

Task での Success Rate

Observed quality varies more by task than by one universal context rule

120 matched trials · all completed · values are end-to-end success counts




120 matched trials · all completed · values are end-to-end success counts

Q4のハンデが伸びるのは Literal だけ

The Q4 disadvantage grows only for literal retrieval

Matched pilot · p50 evidence position · n=10 per task family/cell · descriptive, not a significance test



Q4が常に悪いわけでも、Q4とQ8が常に同じわけでもない。

Agent History : 長い履歴そのものは壊れなかった

300/300

final task success

trajectory 1 → 32 turns

300/300

critical-fact reuse

0

planning errors

むしろ壊れていたのは output protocol


- 以前のpilot : 64-token limit → 30件 invalid output
- recheck : 128-token JSON + 3 action attempts
- 最大completion 109 tokens → 全件成功

履歴長による失敗に見えても、実際には出力制約が原因かもしれない。

Q8_0/Q4_K_M · trajectory 1/4/8/16/32 · 10 tasks × 3 deterministic repeats

Output Protocol を直すと失敗が消えた

Observed agent failures changed with the output protocol





Descriptive comparison: the recheck changed the output budget, JSON policy, and retry policy; this is not a causal ablation

Descriptive comparison: the recheck changed the output budget, JSON policy, and retry policy; this is not a causal ablation

履歴が伸びても Reliability は落ちない

Under the fixed policy, longer agent context did not reduce success



Q8_0/Q4_K_M · 10 independent tasks · 3 greedy repeats per cell · one critical position (50%)

Q8_0/Q4_K_M · 10 independent tasks · 3 greedy repeats per cell · one critical position (50%)

一番大きな学び：LLMより先に、評価器が壊れる

Example

Expected:
ZX-4817

Model output:
ZX-4817.659

exact matchでは失敗。

でも答えを含んでいるか？では別の判定になる。

exact

文字列が完全一致？

answer-bearing

必要な答えを含む？

format

指定形式を守る？

モデルを測る前に、測定器を校正する。

TAKEAWAY

Fits $\neq$ Useful

Local Qwenは動くか？より、
どこで・どう壊れるかを測ると面白い。

1・Quantization

Q4でも answer-bearing はかなり残った

2・Context

window sizeより運用コストが先に効く

3・Evaluation

scorer / format / protocolを分離して見る

Next: full position sweep $\rightarrow$ repository-level validation (exp_005)

宣伝